

Clasificación de razas de perros y gatos a partir de imágenes usando CNN y transfer learning sobre el Oxford-IIIT Pet Dataset

1. Contexto de aplicación

La clasificación automática de imágenes de mascotas es un problema relevante dentro de la visión por computador y del reconocimiento de patrones. Aplicaciones como plataformas de adopción, sistemas de catalogación de refugios, clínicas veterinarias, redes sociales orientadas a mascotas o repositorios de imágenes pueden beneficiarse de modelos capaces de identificar automáticamente la raza de un perro o un gato a partir de una fotografía. Este tipo de tarea no solo permite organizar grandes volúmenes de imágenes, sino también agilizar procesos de etiquetado, búsqueda y filtrado de contenido. Además, se trata de un problema de clasificación fina, ya que muchas razas presentan diferencias visuales sutiles, cambios de pose, iluminación o fondo, lo que lo convierte en un caso apropiado para el uso de redes neuronales convolucionales. El proyecto propuesto se alinea con la guía del curso, que pide aplicar técnicas del módulo a un problema realista sobre datos disponibles y con un alcance controlado.

En este proyecto se propone desarrollar un sistema de clasificación multiclase de imágenes que permita predecir la raza de una mascota a partir de una fotografía. La elección de este problema es adecuada porque pertenece directamente al dominio de la visión por computador, permite aprovechar arquitecturas CNN y técnicas de transfer learning, y ofrece un escenario manejable para construir una primera iteración funcional, tal como recomienda la guía del proyecto.

2. Objetivo de machine learning

El objetivo de machine learning es construir un modelo de **clasificación supervisada multiclase** que, dada una imagen RGB de una mascota, prediga correctamente su raza entre las 37 categorías disponibles en el conjunto de datos. Formalmente, se busca aprender una función $f(x) \rightarrow y$, donde “x” es una imagen y “y” es una etiqueta de raza. La solución se implementará utilizando redes neuronales convolucionales y, como enfoque principal, transfer learning sobre una arquitectura preentrenada, ya que este paradigma está especialmente recomendado cuando no se dispone de un volumen masivo de datos para entrenar un modelo profundo desde cero.

Como línea base del proyecto, se plantea comparar una CNN relativamente simple entrenada sobre el dataset con un modelo basado en transferencia de aprendizaje. Según la documentación oficial de TensorFlow, el transfer learning consiste en reutilizar características aprendidas previamente en un problema grande y adaptarlas a una nueva tarea similar, normalmente congelando parte de la red preentrenada y entrenando nuevas capas finales, con la posibilidad posterior de aplicar fine-tuning. Este enfoque resulta apropiado para clasificación de imágenes y es especialmente útil cuando el dataset del problema específico es moderado en tamaño.

3. Dataset

Para este proyecto se utilizará el Oxford-IIIT Pet Dataset, un conjunto de datos público ampliamente usado en tareas de visión por computador. De acuerdo con la documentación oficial del dataset, contiene imágenes de 37 razas de mascotas, con aproximadamente 200 imágenes por clase, y presenta una alta variabilidad en escala, pose e iluminación. El dataset incluye, además de la imagen, anotaciones de raza y especie; también incorpora máscaras de segmentación y bounding boxes de la cabeza, lo que lo hace útil no solo para clasificación sino también para tareas más avanzadas como segmentación y detección.

En su versión reportada en TensorFlow Datasets, el conjunto contiene 7,349 imágenes distribuidas en 3,680 ejemplos de entrenamiento y 3,669 de prueba, con un tamaño aproximado de 773.68 MiB. El esquema de características incluye la imagen, el nombre del archivo, la etiqueta de clase con 37 categorías, la especie con 2 categorías y la máscara de segmentación. El artículo original del dataset indica además que las 37 clases se dividen en 25 razas de perros y 12 razas de gatos, y que el problema puede formularse tanto como clasificación binaria gato/perro como clasificación completa de raza. En este proyecto se utilizará la formulación más desafiante: clasificación de raza en 37 clases.

Respecto a la distribución de clases, el dataset es relativamente balanceado en comparación con otros problemas de clasificación, ya que cada raza cuenta con cerca de 200 imágenes. Esto es favorable para entrenamiento y evaluación, porque reduce el sesgo hacia clases dominantes y permite usar métricas globales como accuracy con mayor sentido. Sin embargo, sigue siendo un problema difícil, ya que las diferencias entre razas pueden ser muy sutiles, lo cual lo ubica dentro del ámbito de la clasificación fina de imágenes.

4. Métricas de desempeño

Dado que se trata de una tarea de clasificación multiclase relativamente balanceada, una primera métrica de evaluación será la accuracy global, que permitirá medir el porcentaje total de imágenes clasificadas correctamente. Sin embargo, para obtener una evaluación más completa, también se emplearán **precision**, **recall** y **F1-score** por clase, así como una matriz de confusión, ya que estas herramientas permiten identificar en qué razas se concentra la mayoría de errores y qué clases presentan confusiones frecuentes entre sí. El artículo original del dataset reporta el desempeño mediante average per-class classification accuracy, es decir, la exactitud promedio por clase, por lo que esta también será una métrica pertinente para comparar el modelo desarrollado con antecedentes previos.

Desde la perspectiva de negocio o aplicación, las métricas relevantes dependerán del escenario de uso. Si el sistema se aplicara en una plataforma de adopción o en un repositorio de imágenes de mascotas, sería importante medir: **(1)** el porcentaje de imágenes catalogadas automáticamente sin intervención humana, **(2)** la reducción del tiempo promedio de etiquetado manual, **(3)** la tasa de imágenes enviadas a revisión cuando la confianza del modelo sea baja, y **(4)** la proporción de errores críticos de clasificación entre razas visualmente parecidas. Estas métricas complementan las métricas puramente técnicas, porque permiten valorar el impacto práctico del modelo dentro de un flujo real de trabajo.

Adicionalmente, para el desarrollo del proyecto será importante monitorear el comportamiento del modelo durante entrenamiento y validación, observando curvas de pérdida y accuracy para detectar sobreajuste. En este contexto, técnicas como **dropout**, **data augmentation** y **fine-tuning controlado** pueden jugar un papel importante para mejorar la generalización del sistema.

5. Referencias y resultados previos

El Oxford-IIIT Pet Dataset fue introducido por Parkhi, Vedaldi, Zisserman y Jawahar como un benchmark para clasificación de razas de mascotas. En ese trabajo, los autores destacan que el problema es visualmente difícil debido a la deformabilidad de gatos y perros y a las diferencias sutiles entre razas. En su evaluación sobre la tarea de clasificar directamente las 37 razas, reportan una average accuracy cercana al 59%, lo cual se presenta como un resultado alentador dada la dificultad del problema. Este antecedente es importante porque muestra que no se trata de una tarea trivial y proporciona un punto de referencia para comparar el sistema que se construya en el proyecto.

Por otra parte, la documentación oficial de TensorFlow muestra que el transfer learning es una estrategia estándar y efectiva para clasificación de imágenes cuando se trabaja con datasets de tamaño moderado. El flujo recomendado consiste en tomar un modelo preentrenado en una tarea de gran escala, congelar inicialmente la base convolucional, entrenar nuevas capas de clasificación y, opcionalmente, realizar un ajuste fino posterior con una tasa de aprendizaje baja. Esta estrategia ha sido ampliamente adoptada porque reduce tiempos de entrenamiento, mejora la convergencia y permite obtener mejores resultados que entrenar desde cero en muchos escenarios prácticos.

A partir de estos antecedentes, se espera que una línea base basada en CNN permita obtener resultados iniciales razonables, mientras que una solución con transferencia de aprendizaje ofrezca un mejor desempeño y una convergencia más estable. Por tanto, este proyecto no solo es pertinente respecto a los contenidos del módulo, sino que también representa una aplicación realista y bien respaldada por literatura previa y por herramientas modernas de deep learning.

Referencias

Parkhi, O. M., Vedaldi, A., Zisserman, A., & Jawahar, C. V. (2012). *Cats and dogs*. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://www.robots.ox.ac.uk/~vgg/publications/2012/parkhi12a/parkhi12a.pdf>

TensorFlow Datasets. (s. f.). *Oxford_iiit_pet*. TensorFlow. https://www.tensorflow.org/datasets/catalog/oxford_iiit_pet?hl=es

Visual Geometry Group, University of Oxford. (s. f.). *The Oxford-IIIT Pet Dataset*. University of Oxford. <https://www.robots.ox.ac.uk/~vgg/data/pets/>